



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석사학위논문

AutoML과 XAI를 활용한
은행대출연체 예측 모델 연구

동아대학교 경영대학원

디지털금융학과

최 봉 진

2022학년도

AutoML과 XAI를 활용한 은행대출연체 예측 모델 연구

지도교수 김 연 국

이 논문을 경영학석사학위
청구논문으로 제출함

2023년 6월

동아대학교 경영대학원

디지털금융학과

최 봉 진

최봉진의 경영학석사학위
청구논문을 인준함

2023년 6월

위 원 장 이 강 배 (인)

부위원장 김 연 국 (인)

위 원 김 상 진 (인)

국문초록

AutoML과 XAI를 활용한 은행대출연체 예측 모델 연구

디지털금융학과 최 봉 진
지 도 교 수 김 연 국

본 연구는 AI 기술의 핵심 개념인 기계학습과 AutoML, 그리고 설명 가능한 인공지능(XAI) 기술을 활용하여 은행에서 대출연체 예측 모델을 생성하고 해석하는 것을 목적으로 한다.

B은행의 가계 대출 계좌 데이터로 AutoML 오픈소스 소프트웨어인 PyCaret 라이브러리를 사용하여 다양한 연체 예측 모델을 비교하였다. XGBoost 모델이 F1 점수와 Cohen의 Kappa에서 가장 좋은 결과를 보였으며, XGBoost 모델을 사용하여 대출 연체 예측 최종 모델을 구축하였다. 최종 모델을 XAI기법중 하나인 SHAP를 활용하여 SHAP Feature Importance, 전역적인 변수영향도, 지역적인 변수영향도 등으로 설명하였다.

또한 설명이 수월한 통계적 기법인 로지스틱 회귀분석 모델을 구축하여 앞선 XGBoost 모델에 SHAP 기법을 사용해 설명한 내용을 비교하였다. 성능이 우수한 XGBoost 모델에 XAI 기법을 통해 설명한 방식은 설명은

쉽지만 성능이 떨어지는 로지스틱 회귀분석 모델의 해석보다 더 나은 방식이 될 수 있다.

주요어: 대출연체, AutoML, 설명력 높은 인공지능, 예측모형, SHAP

목 차

I. 서론	1
1. 연구의 배경 및 목적	1
II. 이론적 배경	3
1. XAI	3
1) XAI의 정의	3
2) SHAP	4
2. AutoML	5
1) AutoML의 정의	5
2) AutoML의 종류	6
(1) OSS	6
(2) Cloud Provider solutions	6
(3) AutoML Platforms	7
3. 선행연구	7
III. 본론	9
1. 분석데이터	9
2. AutoML 적용	17
3. XGBoost 모델 적용	18
4. SHAP 적용	20
5. 로지스틱 회귀분석 모델과 비교	26

IV. 결론 및 한계점	29
참고문헌	31
Abstract	32

표 목 차

<표-1> 독립변수 - B은행	10
<표-2> 독립변수 - K사	14
<표-3> 독립변수 - N사	17
<표-4> AutoML을 통한 모델 비교	18
<표-5> XGBoost Classifier 하이퍼파라미터 튜닝 결과	19
<표-6> XGBoost Classifier 모델의 성능 지표	20
<표-7> 로지스틱 회귀분석 모델의 계수 및 오즈비	27
<표-8> XGBoost 모델과 로지스틱 회귀분석 모델의 성능 비교	28

그 림 목 차

<그림-1> 일반적인 AI와 XAI 비교	4
<그림-2> Shapley value 예시	5
<그림-3> 종속변수 판단 예시	9
<그림-4> SHAP Feature Importance	21
<그림-5> SHAP Summary Plot	22
<그림-6> SHAP Dependence Plot	24
<그림-7> 연체 여부가 “부” 인 한 대출 계좌에 대한 SHAP Force Plot	25
<그림-8> 연체 여부가 “여” 인 한 대출 계좌에 대한 SHAP Force Plot	25

I. 서론

1. 연구의 배경 및 목적

AI(Artificial Intelligence, 인공지능)는 4차 산업혁명의 핵심 기술이다. 금융, 의료, 자동차 등 많은 산업 분야에서 데이터 분석, 처리, 예측 등에 AI를 활용하고 있다. 그 중 금융 산업에서 사례를 보면 고객의 데이터를 기반으로 학습된 AI가 새로운 고객의 데이터를 기반으로 신용평가를 할 수 있고, 이상 거래 사례를 학습한 AI가 이상 거래를 탐지하여 금융 사고를 예방하고, 반복되는 작업을 학습한 AI가 RPA(Robotic Process Automation) 시스템이 되어 직원들의 업무를 도와주고 있다.

AI는 현대 사회를 비약적으로 변화시킨 기술이지만, AI를 구성하고 있는 복잡한 알고리즘은 왜 이런 결과를 도출했는지에 대해 의문점을 남긴다. 이를 해결하는 방안으로 XAI(eXplainable Artificial Intelligence, 설명 가능한 인공지능)기술이 등장하였다. XAI는 AI가 도출한 결과에 사람이 이해하도록 설명을 가능하게 한다.

기계학습(Machine Learning, 머신러닝)은 AI의 하위 개념 중 하나로, 컴퓨터에게 데이터를 가지고 스스로 학습할 수 있게 하는 방법이다. 컴퓨터가 학습하려면 주어진 데이터의 전처리, 모델의 학습, 평가 등 많은 시간과 과정이 필요하다. 이러한 복잡한 과정들을 자동화하여 생산성을 높이기 위해 만들어진 기계학습 자동화 도구가 AutoML이다. AutoML은 코드 몇 줄로 기계학습모델 생성은 물론 모델의 비교, 최적화, 평가까지 가능하다.

본 연구에서는 B 은행의 대출 계좌 연체 데이터를 활용하여 AutoML로

여러 대출연체 예측 기계학습 모델을 생성, 비교해보고, XAI를 적용해 모델을 해석하고자 한다. XAI를 통해 은행에서 연체를 발생시키는 고객의 특성을 파악하고 대출연체 관리에 보다 효과적인 방안을 제시하고자 한다.

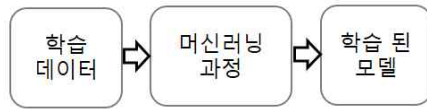
II. 이론적 배경

1. XAI


1) XAI의 정의

XAI는 eXplainable Artificial Intelligence의 약자로, 기존의 AI(Artificial Intelligence, 인공지능) 모델을 사람이 이해할 수 있도록 설명 가능한 기술을 의미한다. AI 모델의 핵심적 구성요소인 기계학습(Machine Learning)모델은 일반적으로 작동 원리가 외부에서 알기 어려운 ‘블랙박스’에 비유된다. 기계학습모델의 알고리즘은 대부분 아주 복잡한 함수들이 조합되어 있어 작동 원리를 외부에서 알기가 어렵고 왜 이러한 결과를 도출했는지 설명하기가 어렵기 때문이다. 이런 기계학습모델의 특성 때문에 잘못된 결과를 도출하였을 때 그 이유를 알기 어려울 수 있으며, 반대로 정확한 결과를 도출하였음에도 이유를 알기 어려워 신뢰도에 의문을 제기할 수 있다. 따라서 XAI는 AI모델을 설명함으로써 모델에 대한 신뢰도를 높일 수 있어 필요성이 점차 대두되고 있다.

일반적인 AI



XAI



사용자의 관점

	일반적인 AI	XAI
의사결정 이해 여부	부	여
성공 여부	부	여
실패 여부	부	여
알고리즘 신뢰 여부	부	여
예러 수정 가능 여부	부	여

<그림 1> 일반적인 AI와 XAI 비교


출처: 방위고등연구계획국(Defense Advanced Research Projects Agency, DARPA).

XAI는 다양한 분야에서 사용될 수 있다. 먼저 의료분야에서 어떤 질병에 대한 예측 모델을 사용할 때, 질병에 걸릴지 안 걸릴지 또는 걸릴 확률이 얼마인지만 판단하는 것이 아니라 예측 모델에 사용된 특징들을 설명 가능하게 한다. 이에 따라 정확한 진단을 할 수 있고 환자들에게도 신뢰를 줄 수 있다. 또 금융 분야에서도 사용될 수 있다. 금융기관에서 AI 기반의 신용 평점 모델이나 대출 심사모델들을 활용하고 있다. 미국에는 신용 기회 평등법(Equal Credit Opportunity Act, ECOA)에 의해 대출을 신청한 고객이 대출 불가 판정을 받았을 때 해당 사유에 대한 설명을 요구할 권리가 있다. XAI를 통해 대출 심사모델을 설명한다면 고객들에게 이러한 권리를 충족시켜 줄 수 있다.

2) SHAP

XAI의 기법 중 본 연구에서는 SHAP(Shapley Additive exPlanations) 기법을 사용하여 모델을 설명한다. SHAP는 Shapley value를 기반으로 하여 모델의 예측값에 대한 각 변수가 미치는 기여도를 측정해서 예측값에 대한 해석을 제공한다. Shapley value는 경제학자 Lloyd Shapley가 게임이

론(game theory)에서 각 플레이어의 기여도를 수치화 한 것으로, 기여도에 따라 상금을 분배하기 위한 방법이다.



<그림 2> Shapley value 예시

예를 들어 <그림 2>와 같이 어느 회사에서 5명으로 이루어진 팀이 프로젝트를 진행한다고 가정한다. 프로젝트 성과에 따른 성과급을 계산할 때 각 팀원의 낸 성과 항목들을 점수로 표현한 기여도가 Shapley value가 되고 성과 항목들이 변수가 될 것이다.

SHAP는 변수 x 의 개수가 n 개일 때 2^n 개의 모델을 생성하여 모든 변수의 유무에 따른 차이를 계산한다. 이를 이용하여 각 변수의 Shapley value 즉, 기여도를 측정하여 변수의 중요도를 파악한다.

2. AutoML

1) AutoML의 정의

AutoML(Automated Machine Learning)은 이름에서 알 수 있듯이 자동화된 기계학습, 즉 기계학습 모델을 자동으로 설계, 구축하는 기술을 말한다. AutoML은 데이터 전처리, 하이퍼파라미터 최적화, 모델 비교 및 선택 등의 어렵고 시간이 많이 소요되는 기계학습 모델 구축 과정을 빠르

고 쉽게 수행할 수 있다. 이를 통해 기계학습 엔지니어, 데이터 과학자들의 업무 효율을 향상시킬 수 있으며, 비전문가들에게 기계학습을 보다 쉽게 접근하고 활용할 수 있게 해준다.

2) AutoML의 종류

(1) OSS(Open Source Software)

OSS 방식은 R, Python 등 기계학습 모델을 구축할 수 있는 환경에 라이브러리 형태로 되어 있는 방식이다. 대표적인 예로 Keras를 기반으로 하는 AutoKeras, Scikit-learn을 기반으로 하는 Auto-sklearn, TPOT 등이 있다. 사용자는 해당 환경에서 라이브러리들을 불러와서 AutoML 기능을 사용할 수 있다. 라이브러리들을 직접 코드로 불러와서 사용하기 때문에 각 사용자에게 맞춤으로 AutoML을 수행하기에 가장 좋다. 그러나 그만큼 사용자가 해야 할 일이 많아지기 때문에 완전한 자동화에는 한계점이 있다.

(2) Cloud Provider solutions

Cloud Provider solutions 방식은 클라우드 환경을 통해서 AutoML을 수행하는 방식이다. 대표적으로 Google Cloud Platform에서의 Cloud AutoML, Microsoft의 Azure, Amazon의 Sagemaker Autopilot 등이 있다. 코드 작성을 하는 Python API, 코드 작성이 불필요한 UI 방식을 모두 제공한다. 클라우드 시스템에서 수행하기 때문에 시스템 할당이 따로 필요 없으며, 데이터 전처리, 모델링, 평가까지 구현 가능하여 사용하기 쉽다.

만, 작업 과정을 정확히 파악하기 힘들다는 단점이 있다.

(3) AutoML Platforms

AutoML Platforms 방식은 AutoML 서비스만을 목적으로 개발된 AutoML 전문 플랫폼을 사용하는 방식이다. 대표적으로 DataRobot과 H2O 등이 있다. AutoML Platform을 사용하기 위한 초기비용이 많이 들어 주로 기업체에서 AutoML을 활용할 때 이용한다. 프로그램 내에서 코드를 직접 조작하기 때문에 OSS 방식에 비해 사용자 맞춤으로 구성하기에는 한계가 있지만, AutoML 서비스를 위해 개발된 플랫폼이어서 가장 간단하게 AutoML을 활용할 수 있다.

3. 선행연구

최근 XAI에 대한 필요성이 대두되면서 관련 연구들이 진행되고 있다.

AI 신뢰성을 위한 XAI 기술 동향에 관한 연구(심혜진, 최창우, 김호원, 2022)에서는 인공지능 모델이 블랙박스 성향을 보이기 때문에 투명성에 대한 요구가 증가하고, 모델의 메커니즘을 이해하기 위해 인공지능 설계 시 “해석 가능성”을 추가로 고려하는 XAI가 등장했다고 하였다. 요즘은 산업 분야에서 XAI 기술의 도입이 두드러지게 나타나고 있는데, 특히 사용자의 신뢰가 필수적인 산업 분야에서 XAI의 중요성이 더욱 주목받고 있으며, 자율주행차, 금융, 의료 등이 대표적인 예시라고 하였다. 앞으로 어떤 산업 분야에서든 인공지능이 적용되는 곳이라면 XAI에 대한 요구가 계속해서 증가할 것으로 보았다.

Scott M. Lundberg와 Su-In Lee(2017)는 모델 예측 해석에 대한 통합 접

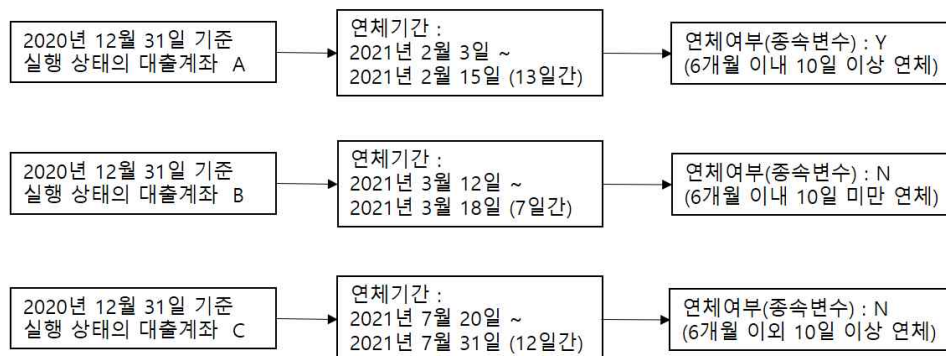
근 방식 연구에서 다양한 모델의 해석 기법 중 게임 이론에 기반한 Shapley Value를 활용한 SHAP의 개념을 소개한다. SHAP로 모델의 각 특성이 예측에 어떻게 기여하는지를 설명하는 지표를 계산하며, 실험을 통해 해당 값이 유의미함을 증명하고 여러 판단 방법을 제시하였다.

Alejandro Barredo Arrieta 등(2019)의 XAI의 개념, 분류, 책임 있는 AI를 향한 기회와 도전 연구에서는 블랙박스 모델을 설명하기 위한 방법을 비교하였다. 지역적 및 전역적 영향도, 사용할 수 있는 데이터 타입 등을 고려해 비교, 분석하였다. 제시된 방법 중에서 SHAP가 가장 포괄적인 방법으로, 모든 모델과 모든 유형의 데이터에 대한 설명을 제공하며 전역 및 지역 범위에서 작동한다고 하였다. 그러나 SHAP에도 단점이 있는데, SHAP의 커널 버전인 KernelSHAP는 대부분의 순열 기반 방법과 마찬가지로 특성 간의 의존성을 고려하지 않기 때문에 종종 불가능한 데이터 포인트에 과도한 가중치를 부여한다. TreeSHAP는 이 문제를 해결하지만, 조건부 예측에 의존하므로 직관적이지 않은 특성 중요도 값을 생성할 수 있으며, 예측에 영향을 미치지 않는 특성에 중요도 값이 0이 아닌 다른 값이 할당될 수 있다고 하였다.

Ⅲ. 본론

1. 분석데이터

본 연구에서는 은행의 대출연체 예측 모형을 구축하기 위해 B 은행의 실제 데이터를 사용하였다. B은행의 가계 대출 계좌로, 2020년 12월 말 기준 실행 상태의 계좌 176,695건, 2021년 6월 말 기준 실행 상태의 계좌 191,136건, 2021년 12월 말 기준 실행상태의 계좌 194,302건, 2022년 6월 말 기준 실행상태의 계좌 194,171건이다. 대출 계좌 기준으로 금리, 잔액 등의 B 은행의 정보들과 외부 신용평가사인 K사, N사에서 들어온 정보들이 포함되어 있다. 연체 여부를 종속변수로 설정하였고, 각 기준 연월을 기준으로 6개월 이내 10일 이상 연체한 계좌의 경우 연체를 한 것으로 판단하였다. 연체를 예측함과 동시에 6개월마다 모니터링하기 위해 6개월 이내 연체 여부를 종속변수로 설정하였다. <그림 3>은 연체 여부 판단에 대한 예시이다.



<그림 3> 종속변수 판단 예시

독립변수는 B 은행 정보 19개, K사 정보 132개, N사 정보 93개 총 244개의 변수를 사용하였고 변수들의 목록은 <표 1>, <표 2>, <표 3>과 같다.

변수명	변수설명	값
TOT_DD	총대출일수	숫자값
PSG_DD	대출경과일수	숫자값
LOAMT	대출금액	숫자값
LO_BAMT	대출잔액	숫자값
DDV	대면비대면구분	D:대면, U:비대면
PYBK_MTD_DVCD	상환방법구분	01:일시상환, 02:원금균등상환 03:일부원금균등상환, 04:원리금균등상환
NTRT	실행금리	숫자값
APY_NTRT	현재금리	숫자값
REPRC_PRD_MT	금리변동주기월수	3, 6, 9, 12
YY	나이구분	A:20세 이하, B:20~24세, C:25~29세 D:30~34세, E:35~39세, F:40~44세 G:45~49세, H:50~54세, I:55~59세 J:60~64세, K:65~69세, L:70~74세 M:75~79세, N:80세 이상
MFDV	성별구분	M:남성, F:여성
CNT	B은행대출건수	숫자값
TOT_LO_BAMT	총대출금액	숫자값
USE_CNT	6개월내 B은행카드결제건수	숫자값
USE_AMOUNT	6개월내 B은행카드결제금액	숫자값
CRDCRD_CNT	B은행신용카드개수	숫자값
CHKCRD_CNT	B은행체크카드개수	숫자값
TOT_DEP_BAMT	6개월내 B은행수신평잔	숫자값
CORE_DEP_BAMT	6개월내 B은행핵심예금평잔	숫자값

<표 1> 독립변수 - B은행

변수명	변수설명	값
K_ITEM_VAL5	1년내(15일)카드일시불최고총이용금액(해지포함)(B	숫자값

	은행카드제외)	
K_ITEM_VAL6	3개월내(15일)카드총이용금액합계(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL13	6개월내(15일)카드이용개월수(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL16	6개월내(15일)카드총이용금액합계(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL17	6개월내(15일)카드일시불총이용금액합계(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL18	연체건수(6개월내발생)(해제포함)	숫자값
K_ITEM_VAL19	연체건수(1년내발생)(해제포함)	숫자값
K_ITEM_VAL20	최장연체일수(3개월내발생)(해제포함)	숫자값
K_ITEM_VAL21	최장연체일수(1년내유지)(해제포함)	숫자값
K_ITEM_VAL22	최고(경험)연체금액(1년내유지)(해제포함)	숫자값
K_ITEM_VAL23	연체건수(미해제)(B은행제외)	숫자값
K_ITEM_VAL24	최장연체일수(1년내유지)(해제포함)(B은행제외)	숫자값
K_ITEM_VAL25	카드업종연체건수(6개월내발생)(해제포함)	숫자값
K_ITEM_VAL26	(K사)최근 대출개설일로부터의 기간	숫자값
K_ITEM_VAL27	(K사)분할상환대출건수	숫자값
K_ITEM_VAL28	(K사)신용대출(담보제외)총잔액	숫자값
K_ITEM_VAL29	대출기관수(KFB)(1년내신규개설)(미해지)	숫자값
K_ITEM_VAL30	대출기관수(KFB)(1년내개설)(대출금액1천만원미만)(미해지)	숫자값
K_ITEM_VAL31	(K사)전체총대출금액대비은행업권총대출금액비율(KFB)	숫자값
K_ITEM_VAL32	(K사)전체총대출금액대비제2금융업권(카드론포함)총대출금액비율(KFB)	숫자값
K_ITEM_VAL33	(K사)주택담보대출제외대출기관수(KFB)	숫자값
K_ITEM_VAL34	은행업권제외대출기관수(KFB)(미해지)	숫자값
K_ITEM_VAL36	(K사)비은행업종대출건수비율(대출건수대비)	숫자값
K_ITEM_VAL37	(K사)비은행업종순수담보제외총대출금액	숫자값
K_ITEM_VAL38	12개월전(15일)신용카드기관수(미해지)	숫자값
K_ITEM_VAL39	1개월전(15일)신용카드이용기관수	숫자값
K_ITEM_VAL40	3개월내(15일)신용카드이용기관수	숫자값
K_ITEM_VAL44	3개월전(15일)신용카드기관수(미해지)	숫자값
K_ITEM_VAL45	6개월전(15일)신용카드기관수(미해지)	숫자값
K_ITEM_VAL46	1개월전(15일)신용카드총이용금액	숫자값
K_ITEM_VAL47	3개월전(15일)신용카드총이용금액	숫자값
K_ITEM_VAL48	6개월전(15일)신용카드총이용금액	숫자값
K_ITEM_VAL49	1개월전카드(15일)신판총이용금액	숫자값
K_ITEM_VAL50	3개월전카드(15일)신판총이용금액	숫자값
K_ITEM_VAL55	3개월내(15일)카드최고총이용금액	숫자값
K_ITEM_VAL56	3개월내(15일)카드일시불최고총이용금액	숫자값
K_ITEM_VAL57	1년내(15일)카드일시불최고총이용금액	숫자값
K_ITEM_VAL61	3개월내(15일)카드월평균총이용금액	숫자값
K_ITEM_VAL62	3개월내(15일)카드일시불월평균총이용금액	숫자값
K_ITEM_VAL66	3개월내(15일)카드총이용금액합계	숫자값

K_ITEM_VAL67	6개월내(15일)카드총이용금액합계	숫자값
K_ITEM_VAL68	3개월내(15일)카드일시불총이용금액합계	숫자값
K_ITEM_VAL69	6개월내(15일)카드일시불총이용금액합계	숫자값
K_ITEM_VAL70	6개월내(15일)카드할부총이용금액합계	숫자값
K_ITEM_VAL75	3개월내(15일)카드최고이용기관수	숫자값
K_ITEM_VAL92	6개월내(15일)카드최고이용기관수	숫자값
K_ITEM_VAL98	6개월내(15일)카드최고총이용금액	숫자값
K_ITEM_VAL104	1년내(15일)카드최고이용기관수	숫자값
K_ITEM_VAL105	3개월내(15일)카드일시불최고이용기관수	숫자값
K_ITEM_VAL106	3개월내(15일)카드월평균이용기관수	숫자값
K_ITEM_VAL109	1년내(15일)카드일시불최고이용기관수	숫자값
K_ITEM_VAL110	6개월내(15일)카드월평균이용기관수	숫자값
K_ITEM_VAL114	연체건수(대지급포함)(1년내유지)	숫자값
K_ITEM_VAL115	총최고(경험)연체금액(대지급포함)(1년내유지)(해제포함)	숫자값
K_ITEM_VAL116	최장연체일수(6개월내발생)(해제포함)	숫자값
K_ITEM_VAL117	최장연체일수(1년내발생)	숫자값
K_ITEM_VAL118	최장연체일수(3개월내유지)	숫자값
K_ITEM_VAL119	최장연체일수(6개월내유지)	숫자값
K_ITEM_VAL120	연체건수(미해제)	숫자값
K_ITEM_VAL121	카드연체건수(1개월내발생)	숫자값
K_ITEM_VAL122	카드연체건수(3개월내발생)	숫자값
K_ITEM_VAL123	연체건수(1년내유지)(해제포함)	숫자값
K_ITEM_VAL124	연체계좌수(1년내유지)(해제포함)	숫자값
K_ITEM_VAL125	연체계좌수(3개월내발생)(해제포함)	숫자값
K_ITEM_VAL126	채무불이행(신용정보사)건수	숫자값
K_ITEM_VAL127	카드업종연체총건수(1년내발생)	숫자값
K_ITEM_VAL128	카드업종총연체일수(1년내유지)(해제포함)	숫자값
K_ITEM_VAL129	카드업종총연체일수(미해제)(B은행카드제외)	숫자값
K_ITEM_VAL130	카드업종최장연체일수(1년내유지)(해제포함)	숫자값
K_ITEM_VAL131	순수담보제외대출건수	숫자값
K_ITEM_VAL132	대출기관수(KFB)(미해지)	숫자값
K_ITEM_VAL134	카드업권대출기관수(KFB)(미해지)	숫자값
K_ITEM_VAL136	저축은행업권대출기관수(KFB)(미해지)	숫자값
K_ITEM_VAL138	대출기관수(KFB)(미해지)(대출금액1천만원미만)	숫자값
K_ITEM_VAL139	2천만원미만 대출 총 기관수	숫자값
K_ITEM_VAL140	카드론대출기관수(KFB)(미해지)	숫자값
K_ITEM_VAL141	소득추정보형(결정연소득금액)	숫자값
K_ITEM_VAL142	소득추정보형(결정연소득등급)	숫자값
K_ITEM_VAL143	KFB최근대출개설일자로부터의경과일수	숫자값
K_ITEM_VAL144	KFB신용카드개설기관수	숫자값
K_ITEM_VAL146	신용카드총연체일수(1년내발생)(해제포함)	숫자값
K_ITEM_VAL147	K사 CB평점	숫자값
K_ITEM_VAL148	K사 CB등급	숫자값
K_ITEM_VAL149	카드대출(리볼빙포함)이용신용카드기관수(미해지)(15일)	숫자값
K_ITEM_VAL157	6개월내(15일)카드론잔액합계(K사)	숫자값
K_ITEM_VAL158	카드론대출금액(KFB)(미해지)	숫자값

K_ITEM_VAL159	전은연 미상환 계좌별 담보대출 총금액	숫자값
K_ITEM_VAL160	전은연 미상환 계좌별 할부금융 총금액	숫자값
K_ITEM_VAL162	전은연 미상환 계좌별 예/적금담보대출 총금액	숫자값
K_ITEM_VAL164	전은연 미상환 계좌별 학자금신용대출 총금액	숫자값
K_ITEM_VAL179	전은연 미상환 계좌별 저축은행업권 신용대출 총금액	숫자값
K_ITEM_VAL180	전은연 미상환 계좌별 저축은행업권 담보대출 총금액	숫자값
K_ITEM_VAL181	전은연 미상환 계좌별 저축은행업권 예/적금담보대출 총금액	숫자값
K_ITEM_VAL184	전은연 미상환 계좌별 은행업권 신용대출 총금액	숫자값
K_ITEM_VAL186	은행업권 미상환 카드론총금액	숫자값
K_ITEM_VAL187	카드업권 카드론 미상환대출 총금액	숫자값
K_ITEM_VAL190	소득추정보형2.0(등록연소득금액)	숫자값
K_ITEM_VAL192	소득추정보형2.0(추정연소득금액)	숫자값
K_ITEM_VAL195	K사연간원리금상환추정액(여전협회, 단위:천원)	숫자값
K_ITEM_VAL196	K사연간원리금상환추정액(K사, 단위:천원)	숫자값
K_ITEM_VAL204	3개월내(15일)카드일시불월평균총이용금액(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL205	최초카드개설일로부터경과일수(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL211	1년내(15일)카드할부총이용금액합계(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL212	6개월내(15일)신용카드미도래잔액합계(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL213	1년내(15일)신용카드신판총이용금액합계(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL214	유효한도신용카드건수(활성카드)(미해지)(B은행카드제외)	숫자값
K_ITEM_VAL215	최초신용카드개설일자로부터경과일수(활성카드)(미해지)(B은행카드제외)	숫자값
K_ITEM_VAL216	6개월내(15일)신용카드일시불총이용금액합계(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL217	1년내(15일)신용카드일시불총이용금액합계(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL222	1년내(15일)카드할부월평균총이용금액(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL223	1년내(15일)카드총이용금액합계(해지포함)(B은행카드제외)	숫자값
K_ITEM_VAL225	KPL서비스(결정연소득금액)	숫자값
K_ITEM_VAL226	대출기관수(KFB계좌단위)(1년내신규개설)(해지포함)(주택, 신차, 예적금, 유가증권담보제외)(B은행카드제외)	숫자값
K_ITEM_VAL227	6개월내(15일)카드일시불월평균총이용금액(해지포함)	숫자값

	함)(B은행카드제외)	
K_ITEM_VAL228	장기카드대출(카드론)대출기관수(KFB계좌단위)(미해지)	숫자값
K_ITEM_VAL230	3개월내카드총이용금액합계(해지포함)	숫자값
K_ITEM_VAL236	최초대출개설일자로부터의경과일수(해지포함)	숫자값
K_ITEM_VAL249	DTI추정모형2.0(DTI,타입3,3개월)[소득추정3.0기준]	숫자값
K_ITEM_VAL250	미래상환능력지수 1.0	숫자값
K_ITEM_VAL252	K사 R-SCORE	숫자값
K_ITEM_VAL253	신용개설가능지수(카드론)	숫자값
K_ITEM_VAL254	신용개설가능지수(캐피탈)	숫자값
K_ITEM_VAL255	신용개설가능지수(저축은행)	숫자값
K_ITEM_VAL259	자산평가지수(거주지매매가)	숫자값
K_ITEM_VAL260	자산평가지수(거주지전세가)	숫자값
K_ITEM_VAL261	연체건수(대지급포함)(6개월내유지)(해제포함) (B은행 실적 제외)	숫자값
K_ITEM_VAL268	카드캐피탈저축은행신용대출및고위험담보대출기관수(CIS계좌단위)(미해지)	숫자값
K_ITEM_VAL272	다중채무위험지수 등급 (7등급 이하 거절)	숫자값
K_ITEM_VAL273	대출기관수(CIS)(미해지)	숫자값
K_ITEM_VAL277	자산평가지수(총자산평가금액_구간)	숫자값
K_ITEM_VAL416	6개월내카드CA이용잔액보유기관수(해지포함) (B은행 실적 제외)	숫자값
K_ITEM_VAL417	1년내(15일)신용카드신판이용개월수(해지포함)	숫자값

<표 2> 독립변수 - K사

변수명	변수설명	값
N_ITEM_VAL21	비대부업계 미해지 거래개설 총 건수	숫자값
N_ITEM_VAL25	최근3개월내총이용금액합계(15일기준)	숫자값
N_ITEM_VAL27	3개월내(15일)카드총이용금액합계(B은행제외)	숫자값
N_ITEM_VAL29	최근6개월내총이용금액합계(15일기준)	숫자값
N_ITEM_VAL35	6개월내(15일)카드총이용금액합계(B은행제외)	숫자값
N_ITEM_VAL52	미상환 대출 총 건수	숫자값
N_ITEM_VAL53	미상환 대출총금액	숫자값
N_ITEM_VAL54	최근6개월내 대출총건수	숫자값
N_ITEM_VAL55	카드업권 미상환 대출 총 건수	숫자값
N_ITEM_VAL56	카드업권 미상환 대출총금액	숫자값
N_ITEM_VAL57	캐피탈업권 미상환 대출 총 건수	숫자값
N_ITEM_VAL58	캐피탈업권 미상환 대출총금액	숫자값
N_ITEM_VAL59	미상환 카드론 대출 총 건수	숫자값
N_ITEM_VAL60	미상환 카드론 대출총금액	숫자값
N_ITEM_VAL67	저축은행업권 미상환 대출 총 건수	숫자값
N_ITEM_VAL68	저축은행업권 미상환 대출총금액	숫자값

N_ITEM_VAL71	최근1년내 미상환 대출총건수	숫자값
N_ITEM_VAL72	최근1년내 미상환 대출총금액	숫자값
N_ITEM_VAL78	미상환 주택담보 대출총건수	숫자값
N_ITEM_VAL79	미상환 주택담보제외 대출총건수	숫자값
N_ITEM_VAL80	최근1년내 미상환 주택담보제외 대출총건수	숫자값
N_ITEM_VAL81	미상환 주택담보제외 은행업권 대출총금액	숫자값
N_ITEM_VAL82	은행업권 제외 미상환 대출 총 건수	숫자값
N_ITEM_VAL83	은행업권제외 미상환 대출총금액	숫자값
N_ITEM_VAL84	은행업권 최초 미상환 대출개설일로부터의 기간	숫자값
N_ITEM_VAL87	미상환 대출 총 건수	숫자값
N_ITEM_VAL88	미상환 대출총금액	숫자값
N_ITEM_VAL89	최초 대출개설일로부터의 기간	숫자값
N_ITEM_VAL97	최근6개월내 대출관련 연체 총 건수 (최초연체발생일기준)	숫자값
N_ITEM_VAL98	최근6개월내 대출관련 최장 연체경험기간 (최초연체발생일기준)	숫자값
N_ITEM_VAL102	최근6개월내 카드관련 연체 총 건수 (최초연체발생일기준)	숫자값
N_ITEM_VAL103	최근6개월내 카드관련 최장 연체경험기간 (최초연체발생일기준)	숫자값
N_ITEM_VAL112	최근3개월내 연체 총 건수 (최초연체발생일기준)	숫자값
N_ITEM_VAL113	최근 3개월내 연체 총 계좌수 (최초연체발생일기준)	숫자값
N_ITEM_VAL114	최근 6개월내 연체 총 건수 (최초연체발생일기준)	숫자값
N_ITEM_VAL115	최근1년내 연체 총 건수 (최초연체발생일기준)(해제후1년경과건제외)	숫자값
N_ITEM_VAL117	최근6개월내 최장 연체경험기간 (최초연체발생일기준)	숫자값
N_ITEM_VAL118	최근1년내 최장연체 경험기간 (최초연체발생일기준)(해제후 1년 경과건 제외)	숫자값
N_ITEM_VAL122	대출관련 미해제 연체 총 건수	숫자값
N_ITEM_VAL123	대출관련 미해제 총 연체 금액	숫자값
N_ITEM_VAL124	대출관련 미해제 연체 총 잔액	숫자값
N_ITEM_VAL125	대출관련 미해제 최장 연체일수(최초연체발생일기준)	숫자값
N_ITEM_VAL126	카드관련 미해제 연체 총 건수	숫자값
N_ITEM_VAL127	카드관련 미해제 총 연체 금액	숫자값
N_ITEM_VAL128	카드관련 미해제 연체 총 잔액	숫자값
N_ITEM_VAL136	미해제 연체 총 건수(B은행제외)	숫자값
N_ITEM_VAL137	(전체)6개월 연체등록건수	숫자값
N_ITEM_VAL139	N사CB(RK0600_000)평점	숫자값
N_ITEM_VAL140	N사CB(RK0600_000)평점구간(자체)	숫자값
N_ITEM_VAL141	N사CBSP평점	숫자값
N_ITEM_VAL142	N사CBSP등급	숫자값
N_ITEM_VAL143	N사LNS평점	숫자값
N_ITEM_VAL144	N사LNS등급	숫자값
N_ITEM_VAL146	카드론리스크평점	숫자값

N_ITEM_VAL147	카드론리스크등급	숫자값
N_ITEM_VAL148	카드론반응평점	숫자값
N_ITEM_VAL149	카드론반응등급	숫자값
N_ITEM_VAL153	N사IncomeIndicator대표소득(단위:만원)	숫자값
N_ITEM_VAL159	최근1년내 저축은행 조회 총건수	숫자값
N_ITEM_VAL160	최근1년내 캐피탈업계 조회 총건수	숫자값
N_ITEM_VAL161	최근1년내 대부업계 조회 총건수	숫자값
N_ITEM_VAL177	N사최종연소득금액(단위:만원)	숫자값
N_ITEM_VAL208	N사연간원리금상환추정액(N사,단위:천원)	숫자값
N_ITEM_VAL288	전은연 은행업권제외 미상환 대출 총건수(신차할부,주택담보 제외)	숫자값
N_ITEM_VAL289	미상환 주택담보제외 대출총금액	숫자값
N_ITEM_VAL290	신용대출(담보제외)총건수	숫자값
N_ITEM_VAL293	전은연 미상환 계좌별 신용대출 총건수	숫자값
N_ITEM_VAL294	전은연 미상환 계좌별 대출 총금액	숫자값
N_ITEM_VAL299	최근1년내총연체금액(최초연체발생일기준)	숫자값
N_ITEM_VAL300	최근3개월내 경험한 연체 총 건수(10만원미만제외)	숫자값
N_ITEM_VAL301	최근6개월내 경험한 연체 총 건수(10만원미만제외)	숫자값
N_ITEM_VAL302	최근1년내 경험한 연체 총 건수(10만원미만제외)	숫자값
N_ITEM_VAL303	최근6개월내 경험한 최장 연체경험기간(10만원미만제외)	숫자값
N_ITEM_VAL304	최근1년내 경험한 최장 연체경험기간(10만원미만제외)	숫자값
N_ITEM_VAL305	12개월내 경험한 소호연체 및 CB연체 총 건수	숫자값
N_ITEM_VAL306	12개월내 경험한 소호연체 및 CB연체 총 연체금액	숫자값
N_ITEM_VAL307	12개월내 경험한 소호연체 및 CB연체 최장 연체일수	숫자값
N_ITEM_VAL308	12개월내 경험한 소호연체 및 CB연체 연체일수합계	숫자값
N_ITEM_VAL321	최근 12개월간 CB평점 연속 최대 하향개월수(RK0600_000)	숫자값
N_ITEM_VAL322	최근 6개월내 최하 CB평점(RK0600_000)	숫자값
N_ITEM_VAL393	전은연 계좌별 미상환 대출 총 기관수(예적금담보/유가증권담보/주택담보/신차제외)	숫자값
N_ITEM_VAL394	전은연 미상환 계좌별 카드캐피탈저축은행 대출 총건수(신차할부, 예적금담보, 주택담보, 유가증권담보 제외)	숫자값
N_ITEM_VAL395	전은연 미상환 계좌별 카드캐피탈저축은행 대출 총금액(신차할부, 예적금담보, 주택담보, 유가증권담보 제외)	숫자값
N_ITEM_VAL398	최근6개월내 경험한 연체 총 건수(10만원미만제외) (B은행제외)	숫자값
N_ITEM_VAL399	대부업계 30일이상 연체 6개월내 경험한 총 건수	숫자값

N_ITEM_VAL400	6개월내 경험한 소호연체 총 건수(B은행제외)	숫자값
N_ITEM_VAL401	12개월내 경험한 소호연체 최장 연체일수	숫자값
N_ITEM_VAL403	전은연 미상환 계좌별 신용대출 총금액	숫자값
N_ITEM_VAL405	최근3개월내 경험한 연체 총 건수(10만원미만제외) (B은행제외)	숫자값
N_ITEM_VAL406	대부업계 30일이상 연체 3개월내 경험한 총 건수	숫자값
N_ITEM_VAL407	3개월내 경험한 소호연체 총 건수(B은행제외)	숫자값
N_ITEM_VAL408	전은연 미상환 계좌별 대출 총건수(예적금/유가증권담보/주택담보/신차할부제외)(카드론인별기준)	숫자값
N_ITEM_VAL412	(전체)1개월 최장연체일수	숫자값

<표 3> 독립변수 - N사

2. AutoML 적용

연체 예측 모델 작성을 위해 먼저 AutoML을 활용하여 여러 모델을 비교하였다. 본 연구에서는 OSS(Open Source Software) 방식의 AutoML 중 PyCaret 라이브러리를 활용하였다. PyCaret 라이브러리는 분류(classification), 군집(clustering), 회귀(regression), 자연어처리(NLP) 등의 패키지가 있다. 연체 여부를 종속변수로 하여 PyCaret을 통한 AutoML 모델 성능 비교는 다음과 같았다.

Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
Extreme Gradient Boosting	0.9907	0.9249	0.2024	0.6328	0.3049	0.3014	0.353
Linear Discriminant Analysis	0.9821	0.9096	0.3746	0.2487	0.2985	0.2899	0.2963
Extra Trees Classifier	0.9909	0.9002	0.1857	0.6997	0.2923	0.2893	0.3565
Random Forest Classifier	0.9909	0.9018	0.177	0.7099	0.2822	0.2793	0.3505
Decision Tree Classifier	0.984	0.6475	0.304	0.2574	0.2784	0.2703	0.2715
Light Gradient	0.9894	0.9282	0.1929	0.4599	0.2707	0.2662	0.2926

Boosting Machine							
Gradient Boosting Classifier	0.9899	0.926	0.123	0.5144	0.197	0.1939	0.2465
Ada Boost Classifier	0.9891	0.914	0.1024	0.3755	0.1604	0.1567	0.1915
Logistic Regression	0.9899	0.9227	0.0817	0.502	0.1396	0.1372	0.1982
Naive Bayes	0.9027	0.8814	0.719	0.0724	0.1315	0.1151	0.2076
K Neighbors Classifier	0.9897	0.6945	0.0492	0.4277	0.0875	0.0857	0.1407
Ridge Classifier	0.9899	0	0.0365	0.5656	0.0683	0.0671	0.1406
Quadratic Discriminant Analysis	0.9542	0.5044	0.0452	0.0094	0.014	0.0016	0.0026
SVM - Linear Kernel	0.9898	0	0	0	0	0	0
Dummy Classifier	0.9898	0.5	0	0	0	0	0

〈표 4〉 AutoML을 통한 모델 비교

평가지표별로 살펴보면 정확도(Accuracy)는 Extra Trees Classifier와 Random Forest Classifier가 0.9909로 가장 높게 나왔고 Extreme Gradient Boosting(XGBoost)가 0.9907의 정확도를 보였다. AUC(Area Under the ROC Curve)는 Light Gradient Boosting Machine이 0.9282, Extreme Gradient Boosting(XGBoost)가 0.9249 순으로 나타났다. 또한 F1 score와 Cohen's Kappa는 모두 Extreme Gradient Boosting(XGBoost)가 가장 높은 지표를 보여주었다.

본 연구에서는 F1 score와 Cohen's Kappa가 가장 높은 XGBoost 모델로 은행의 대출연체 예측 모형을 구축하였다.

3. XGBoost 모델 적용

B 은행의 대출 데이터로 XGBoost 기법을 적용하였다. 훈련 데이터를 2020년 12월 말 기준 대출 계좌, 2021년 6월 말 기준 대출 계좌, 2021년 12월 말 기준 대출 계좌로 하였고, 테스트 데이터를 2022년 6월 말 기준

대출 계좌로 설정하였다.

데이터의 수가 많아 주어진 범위 안에서 무작위로 숫자를 선택해 최적의 하이퍼파라미터를 찾아주는 RandomizedSearchCv를 통해 하이퍼파라미터 튜닝을 진행하였다. 또한 해당 데이터의 종속변수(연체 여부) Y:N 비율은 약 1:99로, 종속변수의 비율이 1% 정도밖에 되지 않는 Class imbalance(클래스 불균형) 문제를 보였다. 이를 해결하기 위해 하이퍼파라미터 중 하나인 scale_pos_weight에 중점을 두고 튜닝하였다. 하이퍼파라미터 튜닝 결과는 <표 5>와 같다.

하이퍼파라미터	값
colsample_bytree	0.895936268590846
gamma	2.5964856853119
learning_rate	0.186769126664773
max_depth	4
min_child_weight	25.0477631607895
n_estimators	234
reg_alpha	140.168985350219
subsample	0.92869718045593
scale_pos_weight	2
nthreads	-1

<표 5> XGBoost Classifier 하이퍼파라미터 튜닝 결과

튜닝된 하이퍼파라미터를 적용하여 연체 예측 모델을 구축하였다. 훈련 데이터로 구축하여 테스트 데이터를 적용한 모델의 결과는 <표 6>과 같다.

구분	스코어
Accuracy	0.98
Precision	0.53
Recall	0.23
F1	0.32
AUC	0.61
Cohen's Kappa	0.31


〈표 6〉 XGBoost Classifier 모델의 성능 지표

정밀도(Precision)는 0.53, 재현율(Recall)은 0.23, F1 score는 0.32, AUC 0.61, Cohen' s Kappa 0.31로 각각 측정되었다.

4. SHAP 적용

XGBoost 모델에 SHAP 기법을 적용하여 변수들이 어떤 영향을 주는지 알아보았다.

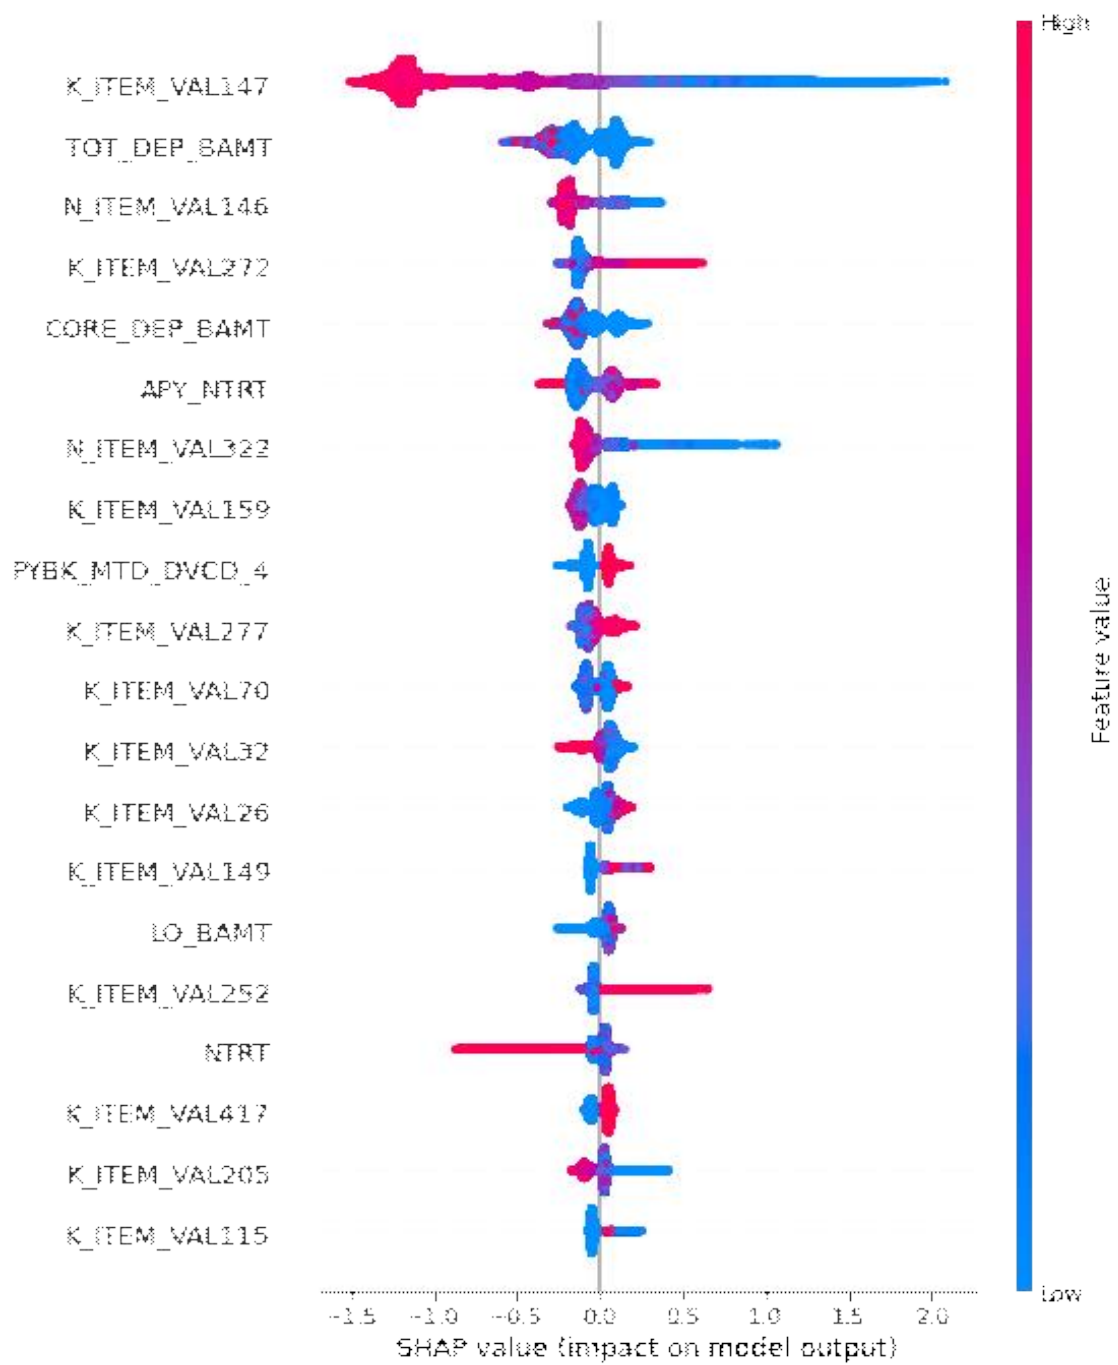
먼저 〈그림 4〉는 전체 변수들이 Shapley Value 분포에 어떤 영향을 미치는지 볼 수 있는 SHAP Feature Importance이다. Shapley Value의 절댓값의 평균을 통해 기여도를 확인할 수 있다.



〈그림 4〉 SHAP Feature Importance

K_ITEM_VAL147 변수 (K사 CB 평점)의 Shapley Value의 절댓값이 0.89로 가장 기여도가 큼을 알 수 있었다. 그다음으로 TOT_DEP_BAMT (B은행의 6개월 내 수신평균잔액) 변수와 N_ITEM_VAL146 (N사 카드론리스크평점) 변수가 Shapley Value의 절댓값 0.17로 뒤를 이었다.

다음으로 〈그림 5〉는 변수 중요도(feature importance)와 변수 효과(feature effects)가 결합한 SHAP Summary Plot이다. SHAP Summary Plot에서 전역적(global)인 변수 영향도를 알 수 있으며, X축은 Shapley value를 나타내고 Y축은 변수값을 나타낸다. 또한 각 점은 변수에 대한 Shapley value이다.



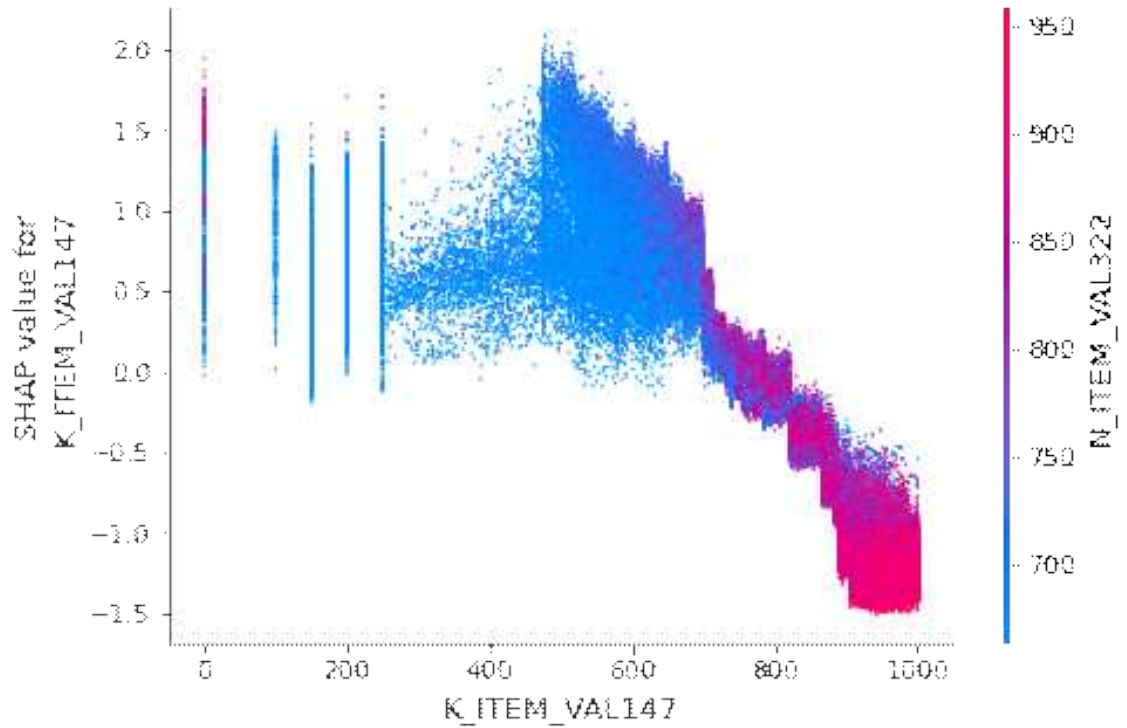
<그림 5> SHAP Summary Plot

SHAP Summary Plot에서 X축의 SHAP value가 0보다 작은 음의 값이면 결과에 부정적(-)인 영향을 미치고, 0보다 큰 양의 값이면 결과에 긍정적(+)인 영향을 미친다. 본 모델에서는 부정적(-) 영향이면 연체를 하지 않는 쪽의 영향이고, 긍정적(+) 영향이면 연체를 하는 쪽으로 영향을 준다. 또 변수값(Feature Value)이 클수록 붉은색으로 표현되고 변수 값이 작을수록 푸른색으로 표현된다.

<그림 5>에서 K_ITEM_VAL147 변수 (K사 CB평점)는 값이 클수록 대출 연체여부에 부정적(-)인 영향을 미친다는 것을 볼 수 있다. TOT_DEP_BAMT 변수 (B 은행의 6개월 내 수신평잔)는 값이 작을수록 대출연체 여부에 긍정적(+)인 영향을 미친다. 또한 K_ITEM_VAL272 변수 (다중채무위험지수 등급)는 값이 클수록 대출연체 여부에 긍정적(+)인 영향을 미친다. PYBK_MTD_DVCD_4 변수 (상환 방법 구분, 원리금균등상환 여부)도 값이 클수록 대출연체 여부에 긍정적(+)인 영향을 미친다. 즉 원리금을 같이 상환하는 방식이 대출연체에 영향을 준다는 것이다.

종합해보면 K사 평점, B은행의 수신 잔액 등은 값이 작을수록 대출연체가 더 많이 발생하고, K사의 채무위험지수 등급은 값이 클수록 대출연체가 더 많이 발생한다고 생각할 수 있다.

다음은 특정 변수끼리의 영향도를 알 수 있는 SHAP Dependence Plot이다. <그림 6>은 모델에 가장 큰 영향을 준 K_ITEM_VAL147 변수 (K사 CB평점)에 대한 SHAP Dependence Plot이다.




〈그림 6〉 SHAP Dependence Plot


K_ITEM_VAL147 변수에 가장 큰 영향도를 주는 변수는 N_ITEM_VAL322(최근 6개월내 최하 CB평점)임을 알 수 있다. X축은 K_ITEM_VAL147 변수의 값, Y축은 K_ITEM_VAL147 변수의 Shap Value 이다. 붉은색일수록 N_ITEM_VAL322 변수의 값이 크고 푸른색일수록 값이 작다. 두 변수가 값이 커질수록 K_ITEM_VAL147 변수의 Shap Value가 작아져 대출연체 여부에 부정적(-)인 영향을 주고, 두 변수의 값이 작아질수록 K_ITEM_VAL147 변수의 Shap Value가 커져 대출연체여부에 긍정적(+)인 영향을 주는 것을 확인할 수 있다.

다음으로 SHAP Force Plot은 각 대출 계좌별로 변수들의 지역적(local)인 영향도를 알 수 있다. 〈그림 7〉과 〈그림 8〉은 각각 종속변수인 연체

여부가 “부” 인 대출 계좌와 “여” 인 대출 계좌의 SHAP Force Plot이다.



〈그림 7〉 연체 여부가 “부” 인 한 대출 계좌에 대한 SHAP Force Plot



〈그림 8〉 연체 여부가 “여” 인 한 대출 계좌에 대한 SHAP Force Plot

SHAP Force Plot에서는 붉은색 부분이 대출연체 예측에 긍정적(+)인 영향을 미치고, 푸른색 부분이 예측에 부정적(-)인 영향을 미친다. 그리고 각 변수가 나타내는 크기가 클수록 영향도가 크다.

〈그림 7〉에서 푸른색 부분이 붉은색 부분보다 크므로 해당 계좌의 푸른색 변수들은 대출연체가 되지 않는 영향을 더 많이 준 것을 알 수 있다.

K_ITEM_VAL147 변수 (K사 CB 평점), TOT_DEP_BAMT 변수 (B 은행의 6개월 내 수신평잔), N_ITEM_VAL146 변수 (N사 카드로리스크평점) 순으로 대출연체 여부에 부정적(-) 영향을 미쳤다.

<그림 8>에서는 붉은색 부분이 푸른색 부분보다 크므로 해당 계좌의 붉은색 변수들은 대출연체가 되는 영향을 더 많이 주었다. K_ITEM_VAL147 변수 (K사 CB 평점), K_ITEM_VAL20 변수 (K사 최장연체일수(3개월 내 발생)(해제포함)), K_ITEM_VAL252 (K사 R-SCORE) 변수 순으로 대출연체 여부에 긍정적(+) 영향을 미쳤다.

5. 로지스틱 회귀분석 모델과 비교

로지스틱 회귀분석은 종속 변수가 이진 형태를 가지고 있을 때 사용되는 통계적 기법이다. 로지스틱 회귀분석은 독립 변수와 종속 변수 사이의 선형 관계를 나타내는 선형 예측 함수를 사용하기 때문에 계수들을 통해 각 독립 변수의 영향력을 평가할 수 있고, 이를 통해 변수의 중요도를 파악할 수 있어서 설명에 수월한 기법이다.

설명이 어려운 모델인 XGBoost모델에 SHAP 기법을 사용해 설명한 앞선 내용과 설명이 수월한 로지스틱 회귀분석 모델을 비교해보고자 한다.

데이터의 변수가 많아 변수 선택과 모델의 복잡도를 조절하기 위해 사용되는 정규화 기법인 Lasso를 사용하였다. Lasso는 기존의 선형 회귀 모델에 L1 규제를 추가하여 모델의 가중치를 제한하는 방식으로 동작한다. L1 규제는 모델의 가중치 중 일부를 0으로 만들어 변수 선택을 하여 중요하지 않은 변수들을 제거하고 더 간단한 모델을 만들 수 있다.

L1 규제를 통해 선택된 변수의 계수(Coefficient)와 오즈비(Odds ratio)는

다음과 같다.

변수	설명	계수	오즈비
K_ITEM_VAL147	KCB CB평점	-0.55728	0.5727
K_ITEM_VAL272	다중채무위험지수 등급 (7등급 이하 거절)	0.329502	1.3902
N_ITEM_VAL147	카드론리스크등급	0.24987	1.2838
N_ITEM_VAL322	최근 6개월내 최하 CB평점(RK0600_000)	-0.1555	0.8559
K_ITEM_VAL215	최초신용카드개설일자로부터경과일수(활성카드) (미해지)(B은행카드제외)	-0.06927	0.933
K_ITEM_VAL19	연체건수(1년내발생)(해제포함)	0.06072	1.0626
K_ITEM_VAL250	미래상환능력지수 1.0	0.050669	1.0519
N_ITEM_VAL67	저축은행업권 미상환 대출 총 건수	0.034908	1.0355
K_ITEM_VAL252	KCB R-SCORE	0.032921	1.0334
K_ITEM_VAL228	장기카드대출(카드론)대출기관수(KFB계좌단위)(미해지)	-0.0292	0.9712
K_ITEM_VAL140	카드론대출기관수(KFB)(미해지)	-0.0292	0.9712
K_ITEM_VAL27	(KCB)분할상환대출건수	0.025881	1.0262
CRDCRD_CNT	신용카드 개수	-0.02065	0.9795
K_ITEM_VAL121	카드연체건수(1개월내발생)	0.01079	1.0108
K_ITEM_VAL186	은행업권 미상환 카드론총금액	-0.00483	0.9951
N_ITEM_VAL142	NiceCBSP등급	0.000651	1.0006

<표 7> 로지스틱 회귀분석 모델의 계수 및 오즈비

계수의 절댓값은 K_ITEM_VAL147 변수 (K사 CB 평점), K_ITEM_VAL272 (다중채무위험지수 등급), N_ITEM_VAL147 (카드론리스크등급) 등 순으로 나타났다.

앞선 내용의 XGBoost 모델을 SHAP를 통해 해석한 결과와 비교했을 때 K_ITEM_VAL147 변수 (K사 CB 평점), K_ITEM_VAL272 변수 (다중채무 위험지수 등급), N_ITEM_VAL322 변수 (최근 6개월내 최하 CB평점) 등이 로지스틱 회귀분석 모델에서도 중요 변수로 나타났다.

다음은 XGBoost 모델과 로지스틱 회귀분석 모델의 성능비교이다.

구분	XGBoost	로지스틱 회귀분석
Accuracy	0.98	0.98
Precision	0.53	0.58
Recall	0.23	0.10
F1	0.32	0.17
AUC	0.61	0.55
Cohen's Kappa	0.31	0.16

<표 8> XGBoost 모델과 로지스틱 회귀분석 모델의 성능 비교

XGBoost 모델의 재현율(Recall), F1 score, AUC, Cohen' s Kappa 점수가 로지스틱 회귀분석 모델의 점수보다 높음을 알 수 있었다. XGBoost 모델의 성능이 로지스틱 회귀분석 모델보다 성능이 더 좋다고 볼 수 있다.

따라서 상대적으로 성능이 우수한 XGBoost 모델을 XAI 기법을 통해 설명한 방식은 설명은 쉽지만 상대적으로 성능이 떨어지는 로지스틱 회귀분석 모델의 해석보다 더 나은 방식이 될 수 있다.

IV. 결론 및 한계점

본 연구에서는 B 은행의 2020년 12월, 2021년 6월, 2021년 12월, 2022년 6월 기준의 대출 계좌 데이터를 합쳐서 AutoML을 통해 여러 모델을 비교 후, XGBoost 기법으로 대출연체 예측 모델을 최종적으로 구현하였다. 또한 XAI의 기법 중 SHAP를 활용하여 변수 중요도 및 전역적, 지역적 변수 영향도를 설명하였다.

Shapley Value의 절댓값을 통해 K사 CB 평점, B 은행의 6개월 내 수신 평잔, N사 카드론리스크평점, K사 다중채무위험지수 등급, B 은행의 6개월 내 핵심예금평잔, 대출 계좌의 현재 금리 등의 변수가 중요 변수임을 파악할 수 있었다.

또한 K사 CB 평점, B은행의 6개월 내 수신평잔, N사 카드론리스크평점, B 은행의 6개월 내 핵심예금평잔 등의 변수는 값이 작을수록 대출연체가 됨에 영향을 주었고, K사 다중채무위험지수 등급, 대출계좌의 현재 금리 등의 변수는 값이 클수록 대출연체가 됨에 영향을 주었다.

실제 대출연체가 아닌 임의의 한 계좌의 지역적 변수 영향도는 K사 CB 평점, B 은행의 6개월 내 수신평잔, N사 카드론리스크평점 순으로 설명하였고, 반대로 대출연체인 임의의 한 계좌는 K사 CB 평점, K사 최장연체일수(3개월 내 발생)(해제포함), K사 R-SCORE 순으로 설명하였다.

또한 일반적으로 설명하기 쉬운 모델인 로지스틱 회귀분석 모델을 구현하여 앞선 XGBoost 모델을 SHAP를 활용하여 설명한 내용을 비교해보았는데, 몇몇 같은 변수들이 중요 변수로 나타났으며 XGBoost 모델이 높은 성능을 보였다. 따라서 성능이 우수한 XGBoost 모델을 SHAP를 통해 설명한 방식이 설명은 쉽지만 성능이 떨어지는 로지스틱 회귀분석 모델

의 해석보다 더 나은 방식이 될 수 있다.

본 연구는 실제 은행의 대출 계좌 데이터를 사용하여 대출연체 예측 모델을 작성한 점과 SHAP를 활용하여 예측 모델에 대한 설명을 했다는 점에서 은행 업무와 학술적인 부분 모두 의미가 있다.

하지만 몇 가지 부분에 있어 연구의 한계점이 존재한다. 먼저 본 연구에서 활용한 데이터가 클래스 불균형(Class Imbalance)을 보였다. 종속변수의 데이터양 차이가 크게 났는데, 연체인 대출 계좌와 연체가 아닌 대출 계좌의 비율이 약 1:99로 연체인 대출 계좌가 전체 대출 계좌의 약 1%밖에 되지 않았다. 이 때문에 scale_pos_weight에 중점을 두고 하이퍼파라미터를 튜닝하였음에도 예측 모델의 스코어가 높게 나오지 못했다. 다양한 방법을 통해 클래스 불균형 문제를 해결하여 더 나은 스코어가 나올 수 있다면 SHAP를 활용한 모델의 설명에서도 더 정확한 설명을 할 수 있을 것이다.

다음으로 연구 결과에서 알 수 있듯이 외부 기관에서 제공한 평점 관련 변수들이 높은 중요도와 영향도를 보였다는 점이다. 외부 기관의 평점은 어떻게 산출이 되었는지 근거에 대해 정확히 알 수 없어서 실제 은행 업무에서는 대출 연체 예측은 할 수 있지만 평점은 관리하기가 힘들 수 있다. 평점 외에 정확히 근거를 알 수 있는 변수들로 모델을 구성한다면 더욱 좋은 설명 가능한 모델이 될 수 있을 것이다.

참고문헌

이재준, 이유린, 임도현, & 안현철. (2021). XGBoost 와 SHAP 기법을 활용한 근로자 이직 예측에 관한 연구. 정보시스템연구, 30(4), 21-42.

심혜진, 최창우, & 김호원. (2022). AI 신뢰성을 위한 XAI 기술 동향. 한국정보처리학회 학술대회논문집, 29(2), 405-407.

Qiu, W., Chen, H., Dincer, A. B., Lundberg, S., Kaeberlein, M., & Lee, S. I. (2022). Interpretable machine learning prediction of all-cause mortality. Communications Medicine, 2(1), 125.

Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. Advances in neural information processing systems, 30.

Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., ... & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. Information fusion, 58, 82-115.

Abstract

A Study on Bank Loan Delinquency Prediction Model Using AutoML and XAI

by

CHOE BONG JIN

*Dept. of Digital Finance,
Graduate School of Business Administration,
Dong-A University
Busan, Korea*

This study aims to develop and interpret loan delinquency prediction models using AutoML and explainable artificial intelligence (XAI). Using the PyCaret, an AutoML library, we developed and compared various delinquency prediction models for retail loan account data from a bank in South Korea. Among models developed by the AutoML, we chose a XGBoost model, as our final model, that showed the best F1 score and Cohen's Kappa. We applied SHAP model, one of the XAI techniques to our final mode and calculated SHAP Feature Importance, Global

Variable Influence, and Local Variable Influence. We also built a logistic regression model, which is an inherently interpretable model, to compare with our XGBoost with the SHAP model. Comparing the two, our XGBoost with the SHAP model shows better performance in terms of predictive power and explainability.